



**FACULTAD de  
CIENCIAS ECONÓMICAS**

## **ESCALAMIENTO MULTIDIMENSIONAL**

ALAN REYES-FIGUEROA  
ELEMENTS OF MACHINE LEARNING

(AULA 09) 16.FEBRERO.2023

# Escalamiento multidimensional

Dada una matriz de datos  $\mathbf{x} \in \mathbb{R}^{n \times d}$ ,  $n > d$ , asociamos a cada vector  $\mathbf{x}_i \in \mathbb{R}^d$  de la matriz, un representante  $\mathbf{x}_i^* \in \mathbb{R}^r$ , (estamos proyectando a un espacio de dimensión menor) de modo que en el nuevo espacio, se preserven las distancias lo mejor posible.

$$\min_{\mathbf{x}_i^*, \mathbf{x}_j^*} \sum_{i=1}^n \sum_{j=1}^n (d(\mathbf{x}_i, \mathbf{x}_j)^2 - d(\mathbf{x}_i^*, \mathbf{x}_j^*)^2)^2. \quad (1)$$

Consideremos las matrices de distancias al cuadrado

$$\mathbb{D}^2 = (d(\mathbf{x}_i, \mathbf{x}_j)^2), \quad \mathbb{D}^{*2} = (d(\mathbf{x}_i^*, \mathbf{x}_j^*)^2) \in \mathbb{R}^{n \times n}.$$

Con esta notación, la ecuación (1) se escribe como

$$\min_{\mathbf{x}_i^*, \mathbf{x}_j^*} \|\mathbb{D}^2 - \mathbb{D}^{*2}\|_F^2.$$

# Escalamiento multidimensional

Además, consideramos las matrices de Gram

$$\mathbb{G} = \mathbb{X}\mathbb{X}^T = (\mathbf{x}_i^T \mathbf{x}_j) = (\langle \mathbf{x}_i, \mathbf{x}_j \rangle), \quad \mathbb{G}^* = \mathbb{X}^*(\mathbb{X}^*)^T = ((\mathbf{x}_i^*)^T \mathbf{x}_j^*) = (\langle \mathbf{x}_i^*, \mathbf{x}_j^* \rangle) \in \mathbb{R}^{n \times n}.$$

Tenemos una relación entre distancias y productos internos:

Denotamos  $g_{ij} = \langle \mathbf{x}_i, \mathbf{x}_j \rangle = \mathbf{x}_i^T \mathbf{x}_j$ . Entonces,

$$\begin{aligned} d_{ij}^2 &= \|\mathbf{x}_i - \mathbf{x}_j\|^2 = \langle \mathbf{x}_i - \mathbf{x}_j, \mathbf{x}_i - \mathbf{x}_j \rangle = \langle \mathbf{x}_i, \mathbf{x}_i \rangle - 2\langle \mathbf{x}_i, \mathbf{x}_j \rangle + \langle \mathbf{x}_j, \mathbf{x}_j \rangle \\ &= g_{ii} - 2g_{ij} + g_{jj}. \end{aligned}$$

Recordemos que si  $\mathbb{J} = I - \frac{1}{n}\mathbf{1}\mathbf{1}^T$ , entonces  $\mathbb{J}$  es una matriz de proyección, y  $\mathbb{X}_c = \mathbb{J}\mathbb{X}$  es la matriz de datos centrados.

Luego,  $\mathbb{G} = \mathbb{X}\mathbb{X}^T \Rightarrow \mathbb{G}_c = \mathbb{X}_c\mathbb{X}_c^T = (\mathbb{J}\mathbb{X})(\mathbb{J}\mathbb{X})^T = \mathbb{J}\mathbb{X}\mathbb{X}^T\mathbb{J}^T = \mathbb{J}\mathbb{X}\mathbb{X}^T\mathbb{J} = \mathbb{J}\mathbb{G}\mathbb{J}$ .

# Escalamiento multidimensional

Recordemos que la matriz de proyección para un conjunto de  $n$  datos,  $\mathbb{J}$ , está dada por

$$\mathbb{J} = I_n - \frac{1}{n} \mathbf{1}\mathbf{1}^T.$$

Esto es

$$\mathbb{J} = \begin{pmatrix} 1 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 \\ 0 & 0 & 1 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & 1 \end{pmatrix} - \frac{1}{n} \begin{pmatrix} 1 & 1 & 1 & \dots & 1 \\ 1 & 1 & 1 & \dots & 1 \\ 1 & 1 & 1 & \dots & 1 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 1 & 1 & 1 & \dots & 1 \end{pmatrix}.$$

Esta matriz sirve para

- centrar la matriz de datos  $\mathbb{X}$ , mediante el cálculo  $\mathbb{X}_c = \mathbb{J}\mathbb{X}$ .
- centrar la matriz de Gram  $\mathbb{G}$ , mediante el cálculo  $\mathbb{G}_c = \mathbb{J}\mathbb{G}\mathbb{J}$ .

# Escalamiento multidimensional

Si queremos proyectar a un espacio de dimensión  $r$ ,  $0 < r \leq d$ , por el Teorema de Eckart-Young, la solución a este problema está dada de la siguiente forma: Si

$$\mathbb{G}_c = USV^T = \sum_{i=1}^d \sigma_i \mathbf{u}_i \mathbf{u}_i^T,$$

es la descomposición SVD de  $\mathbb{G}_c$ , entonces  $\mathbb{G}_c^*$  es

$$\mathbb{G}_c^* = U_r S_r V_r^T = \sum_{i=1}^r \sigma_i \mathbf{u}_i \mathbf{u}_i^T.$$

¿Para qué se hace esto?

- No siempre es posible representar datos como vectores.
- Más adelante vamos a hacer el análisis sin referirnos explícitamente a los  $\mathbf{x}_j$ . En lugar de ello, usaremos distancias o algún otro tipo de métrica.

# Escalamiento multidimensional

Objetivo: Crear coordenadas (sintéticas) en los datos, a partir una matriz de distancias.

Receta para hacer escalamiento multidimensional:

1. Dada una matriz de distancias  $\mathbb{D} \in \mathbb{R}^{n \times n}$ , simétrica, entre  $n$  datos.
2. Calcular la matriz de productos internos  $\mathbb{G}_c = -\frac{1}{2}\mathbb{J}\mathbb{D}\mathbb{J}$ , con  $\mathbb{J} = I_n - \frac{1}{n}\mathbf{1}\mathbf{1}^T$ .
3. Hallar la descomposición SVD de  $\mathbb{G}_c$

$$\mathbb{G}_c = U\Sigma V^T.$$

4. Si queremos representar los datos como vectores en  $\mathbb{R}^k$ , con  $1 \leq k \leq n$ , tomamos la proyección de  $\mathbb{D}$  generada por las primeras  $k$  columnas de  $V$ :


$$\mathbb{X} = \mathbb{D} V[:, : k].$$

# Ejemplo

Ejemplo: Distancias entre 21 ciudades europeas (en Km).

	Athens	Barcelona	Brussels	Calais	Cologne	Copenhagen	...
Athens	0	3313	2963	3175	2762	3276	...
Barcelona	3313	0	1318	1326	1498	2218	...
Brussels	2963	1318	0	204	206	966	...
Calais	3175	1326	204	0	409	1136	...
Cologne	2762	1498	206	409	0	760	...
Copenhagen	3276	2218	966	1136	760	0	...
⋮	⋮	⋮	⋮	⋮	⋮	⋮	⋮


# Ejemplo





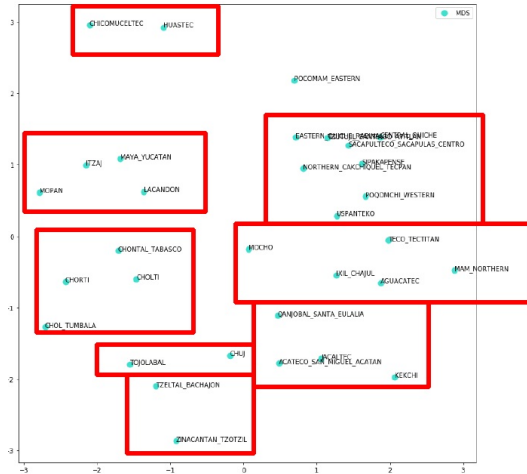
# Ejemplo

## Ejemplo: Idiomas mayas



Matriz de distancias entre idiomas mayas.

## Ejemplo



## Escalamiento multidimensional a 2 dimensiones.